



## 第六章 参数估计

### § 6.1 点估计的概念与无偏性

#### 1. 统计中的参数常指以下几种情况

- 分布中所含的未知参数  $\theta$  及其某个函数  $g(\theta)$ .
- 分布的各种特征数,如期望、方差、中位数等.

参数  $\theta$  可能取值的范围  $\Theta$  称为参数空间.

#### 2. 参数估计的两种形式:点估计与区间估计

参数的点估计是指:对未知参数  $\theta$  选用一个统计量  $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$  的取值作为  $\theta$  的估计值,  $\hat{\theta}$  就是  $\theta$  的点估计(量),简称估计.好的点估计来自好的统计思想.区间估计见 § 6.6.

#### 3. 无偏性与可估参数

设  $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$  是  $\theta$  的一个估计,  $\theta$  的参数空间为  $\Theta$ , 若对任意的  $\theta \in \Theta$ , 有

$$E(\hat{\theta}) = \theta,$$

则称  $\hat{\theta}$  是  $\theta$  的无偏估计, 否则称为有偏估计.

假如对任意  $\theta \in \Theta$ , 有  $\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$ , 则称  $\hat{\theta}$  是  $\theta$  的渐近无偏估计.

并不是所有的参数都存在无偏估计, 当参数存在无偏估计时称该参数是可估的.

#### 4. 有效性 设 $\hat{\theta}_1, \hat{\theta}_2$ 是 $\theta$ 的两个无偏估计, 如果对任意的 $\theta \in \Theta$ 有

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

且至少有一个  $\theta \in \Theta$  使得上述不等号严格成立, 则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效.

## § 6.2 矩估计及相合性

**1. 矩法估计** 利用如下两句“替换原理”而获得的估计量称为矩估计.

- 用样本矩替换总体矩,这里的矩可以是原点矩,也可以是中心矩.
- 用样本矩的函数去替换相应的总体矩的函数.

(1) 在总体分布未知场合,可用矩法对一些参数作出估计,如:

- 用样本均值  $\bar{x}$  估计总体均值  $E(X)$ .
- 用样本方差  $s_n^2$  估计总体方差  $\text{Var}(X)$ .
- 用事件  $A$  出现的频率估计事件  $A$  发生的概率  $P(A)$ .
- 用样本分位数估计总体分位数.

(2) 在总体分布列或分布密度函数形式已知场合,在有关各阶矩存在的条件下,用“总体矩等于样本矩”列出矩方程(组),解之即得分布中未知参数的矩估计.其中尽量选用低阶矩.

**2. 相合性** 设  $\theta \in \Theta$  为未知参数,  $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$  是  $\theta$  的一个估计量,  $n$  是样本容量,若对任何一个  $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0, \quad \forall \theta \in \Theta,$$

则称  $\hat{\theta}_n$  为参数  $\theta$  的相合估计.

相合性本质上就是按概率收敛,它是估计量的一个基本要求,即当样本量不断增大时,相合估计按概率收敛于未知参数.

矩法估计一般都是相合估计.

### 3. 判断相合性的一些定理

(1) 设  $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$  是  $\theta$  的一个估计量,若  $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$ ,  $\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$ , 则  $\hat{\theta}_n$  是  $\theta$  的相合估计.

(2) 若  $\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk}$  分别是  $\theta_1, \theta_2, \dots, \theta_k$  的相合估计,  $\eta = g(\theta_1, \theta_2, \dots, \theta_k)$  是  $\theta_1, \theta_2, \dots, \theta_k$  的连续函数,则  $\hat{\eta}_n = g(\hat{\theta}_{n1}, \hat{\theta}_{n2}, \dots, \hat{\theta}_{nk})$  是  $\eta$  的相合估计.

(3) 大数定律.

## § 6.3 最大似然估计与 EM 算法

**1. 最大似然估计** 利用“最大似然原理”获得的估计,它只能在总体概率函数形式已知的情况下使用,具体步骤如下:设总体的概率函数为  $p(x; \theta), \theta \in \Theta, x_1, x_2, \dots, x_n$  是来自该总体的样本.

- 写出似然函数  $L(\theta) = L(\theta; x_1, x_2, \dots, x_n) = p(x_1; \theta) \cdot p(x_2; \theta) \cdot \dots \cdot p(x_n; \theta)$ .

- 使似然函数  $L(\theta)$  达到最大的统计量  $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$  称为  $\theta$  的最大似然估计,简称 MLE,即  $\hat{\theta}$  满足  $L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta)$ .

注意:使得对数似然函数  $\ln L(\theta)$  最大的  $\hat{\theta}$  也使似然函数  $L(\theta)$  最大,寻找最大值可以从定义出发,也可以对  $l(\theta) = \ln L(\theta)$  使用微分法,后者更为常用.

**2. 最大似然估计的不变性** 若  $\hat{\theta}$  是  $\theta$  的最大似然估计,则对任一函数  $g(\theta), g(\hat{\theta})$  是其最大似然估计.

**3. EM 算法** 当分布中有多余参数或数据为截尾或缺失时,其 MLE 的求取是比较困难的.登普斯特(Dempster)等人于 1977 年提出了 EM 算法,其含义是把求 MLE 的过程分两步走,第一步求期望(E 步),以便把多余的部分去掉,第二步求极大值(M 步).重复使用这两步直至收敛可得 MLE 的近似解.这是一种非常有效的方法.

**4. MLE 的渐近正态性** 在一般条件下,总体分布  $p(x; \theta)$  中  $\theta$  的 MLE  $\hat{\theta}_n$  具有相合性和渐近正态性,即  $\hat{\theta}_n \sim AN\left(\theta, \frac{1}{nI(\theta)}\right)$ ,其中  $n$  为样本容量,

$I(\theta) = \int_{-\infty}^{\infty} \left(\frac{\partial \ln p}{\partial \theta}\right)^2 p(x; \theta) dx$  为费希尔信息量.

## § 6.4 最小方差无偏估计

**1. 均方误差** 设  $\hat{\theta}$  是  $\theta$  的一个估计(无偏的或有偏的),则称

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2$$

为 $\hat{\theta}$ 的均方误差.均方误差较小意味着: $\hat{\theta}$ 不仅方差较小,而且偏差( $E(\hat{\theta}) - \theta$ )也小,所以均方误差是评价点估计的最一般标准.

- 使均方误差一致最小的估计量一般是不存在的,但两个估计好坏可用均方误差评估.

- 在无偏估计类中使均方误差最小就是使方差最小.

**2. 一致最小方差无偏估计** 设 $\hat{\theta}$ 是 $\theta$ 的一个无偏估计,如果对另外任意一个 $\theta$ 的无偏估计 $\tilde{\theta}$ ,在参数空间 $\Theta = \{\theta\}$ 上都有

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\tilde{\theta}),$$

则称 $\hat{\theta}$ 是 $\theta$ 的一致最小方差无偏估计,简记为 UMVUE.

**3. 判断准则** 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 是 $\theta$ 的一个无偏估计,  $\text{Var}(\hat{\theta}) < +\infty$ .如果对任意一个满足 $E(\varphi(x_1, x_2, \dots, x_n)) = 0$ 的 $\varphi$ ,都有

$$\text{Cov}_{\theta}(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta,$$

则 $\hat{\theta}$ 是 $\theta$ 的 UMVUE.

#### 4. 充分性原则

- 任一参数 $\theta$ 的 UMVUE 不一定存在,若存在,则它一定是充分统计量的函数.

- 若 $\theta$ 的某个无偏估计 $\hat{\theta}$ 不是充分统计量 $T = T(x_1, x_2, \dots, x_n)$ 的函数,则通过条件期望可以获得一个新的无偏估计 $\tilde{\theta} = E(\hat{\theta} | T)$ ,且方差比原估计的方差要小.

- 考虑 $\theta$ 的估计时,只需要在其充分统计量的函数中寻找即可,该说法对所有统计推断都是正确的.这便是充分性原则.

**5. 费希尔信息量  $I(\theta)$**  设总体的概率函数 $p(x; \theta)$ ,  $\theta \in \Theta$  满足下列条件:

- (1) 参数空间 $\Theta$ 是直线上的一个开区间;
- (2) 支撑 $S = \{x: p(x; \theta) > 0\}$ 与 $\theta$ 无关;
- (3) 导数 $\frac{\partial}{\partial \theta} p(x; \theta)$ 对一切 $\theta \in \Theta$ 都存在;

(4) 对  $p(x; \theta)$ , 积分与微分运算可交换次序, 即  $\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} p(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} p(x; \theta) dx$ ;

(5) 期望  $I(\theta) = E \left[ \frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2$  存在,

则称该期望  $I(\theta)$  为总体分布的费希尔 (Fisher) 信息量.

如果二阶导数对一切  $\theta \in \Theta$  都存在, 则  $I(\theta)$  还可用下式计算

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \ln p(x; \theta) \right].$$

## 6. 常用分布的费希尔信息量

- 二点分布  $b(1, p)$  的费希尔信息量  $I(p) = [p(1-p)]^{-1}$ .
- 泊松分布  $p(\lambda)$  的费希尔信息量  $I(\lambda) = \lambda^{-1}$ .
- 指数分布  $Exp(\lambda)$  的费希尔信息量  $I(\lambda) = \lambda^2$ .
- 正态分布  $N(\mu, 1)$  的费希尔信息量  $I(\mu) = 1$ .
- 正态分布  $N(0, \sigma^2)$  的费希尔信息量  $I(\sigma^2) = \frac{1}{2\sigma^4}$ .
- 正态分布  $N(\mu, \sigma^2)$  的费希尔信息量 (信息矩阵)  $I(\mu, \sigma^2) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 1/(2\sigma^4) \end{pmatrix}$ .

## 7. C - R 不等式

设  $T = T(x_1, x_2, \dots, x_n)$  是未知参数  $g(\theta)$  的一个无偏估计, 若  $g'(\theta) = \frac{\partial g(\theta)}{\partial \theta}$  存在, 则在费希尔信息量  $I(\theta)$  也存在的条件下有

$$\text{Var}(T) \geq [g'(\theta)]^2 / (nI(\theta)).$$

上式称为克拉默-拉奥 (C - R) 不等式,  $[g'(\theta)]^2 / (nI(\theta))$  称为  $g(\theta)$  的无偏估计的方差的 C - R 下界, 简称  $g(\theta)$  的 C - R 下界. 特别, 对  $\theta$  的无偏估计  $\hat{\theta}$ , 有  $\text{Var}(\hat{\theta}) \geq (nI(\theta))^{-1}$ .

注:  $g(\theta)$  的 C - R 下界并不是对任意参数函数  $g(\theta)$  的无偏估计的方差都可达到. 但能达到 C - R 下界的  $g(\theta)$  的估计  $T = T(x_1, x_2, \dots, x_n)$  一定是  $g(\theta)$  的 UMVUE. 方差达到 C - R 下界的无偏估计称为有效估计.

## § 6.5 贝叶斯估计

### 1. 贝叶斯统计推断使用的三种信息

- 总体信息, 总体分布或总体所属分布族提供的信息.
- 样本信息, 从总体中抽取样本所提供的信息.
- 先验信息, 在试验前人们对要做的问题在经验上和资料上所拥有的信息.

### 2. 贝叶斯统计的基本观点

任一未知量  $\theta$  都可看作一个随机变量, 用一个概率分布来描述未知参数是最好的办法, 这个分布称为先验分布.

### 3. 贝叶斯公式的密度函数形式

- 总体依赖于参数  $\theta$  的概率函数在贝叶斯统计中记为  $p(x|\theta)$ , 它表示在随机变量  $\theta$  取某个给定值时总体的条件概率函数.

- 根据参数  $\theta$  的先验信息设法确定先验分布  $\pi(\theta)$ .

- 从贝叶斯观点看, 样本  $x_1, x_2, \dots, x_n$  的产生分两步进行. 首先从先验分布  $\pi(\theta)$  产生一个样本  $\theta_0$ , 然后从  $p(x_1, x_2, \dots, x_n | \theta_0)$  中产生一组样本. 这时样本的联合条件概率函数为  $p(x_1, x_2, \dots, x_n | \theta_0) = \prod_{i=1}^n p(x_i | \theta_0)$ , 这个分布综合了总体信息和样本信息.

- $\theta_0$  是未知的, 它是按先验分布  $\pi(\theta)$  产生的. 为把先验信息综合进去, 不能只考虑  $\theta_0$ , 对  $\theta$  的其他值发生的可能性也要加以考虑, 故要用  $\pi(\theta)$  进行综合. 这样一来, 样本  $x_1, x_2, \dots, x_n$  和参数  $\theta$  的联合分布为  $h(x_1, x_2, \dots, x_n, \theta) = p(x_1, x_2, \dots, x_n | \theta) \cdot \pi(\theta)$ , 这个联合分布把总体信息、样本信息和先验信息三种可用信息都综合进去了.

- 分析的目的是要对未知参数  $\theta$  作统计推断. 在没有样本信息时, 人们只能依据先验分布对  $\theta$  作出推断. 在有了样本观察值  $x_1, x_2, \dots, x_n$  之后, 则应依据  $h(x_1, x_2, \dots, x_n, \theta)$  对  $\theta$  作出推断. 由于  $h(x_1, x_2, \dots, x_n, \theta)$  可分解为  $h(x_1, x_2, \dots, x_n, \theta) = \pi(\theta | x_1, x_2, \dots, x_n) m(x_1, x_2, \dots, x_n)$ , 其中  $m(x_1, x_2, \dots,$

$x_n) = \int_{\Theta} h(x_1, x_2, \dots, x_n, \theta) d\theta = \int_{\Theta} p(x_1, x_2, \dots, x_n | \theta) \pi(\theta) d\theta$  是  $x_1, x_2, \dots, x_n$  的边际概率函数, 它与  $\theta$  无关, 不含  $\theta$  的任何信息. 因此能用来对  $\theta$  作出推断的仅是条件分布  $\pi(\theta | x_1, x_2, \dots, x_n)$ , 它的计算公式是

$$\pi(\theta | x_1, x_2, \dots, x_n) = \frac{h(x_1, x_2, \dots, x_n, \theta)}{m(x_1, x_2, \dots, x_n)} = \frac{p(x_1, x_2, \dots, x_n | \theta) \pi(\theta)}{\int_{\Theta} p(x_1, x_2, \dots, x_n | \theta) \pi(\theta) d\theta},$$

这个条件分布称为  $\theta$  的**后验分布**, 它集中了总体、样本和先验中有关  $\theta$  的一切信息.

后验分布  $\pi(\theta | x_1, x_2, \dots, x_n)$  的计算公式就是用密度函数表示的贝叶斯公式. 它是用总体和样本对先验分布  $\pi(\theta)$  作调整的结果, 贝叶斯统计的一切推断都基于后验分布进行.

**4. 贝叶斯估计** 基于后验分布  $\pi(\theta | x_1, x_2, \dots, x_n)$  对  $\theta$  所作的贝叶斯估计有多种, 常用有如下三种:

- 使用后验分布的密度函数最大值作为  $\theta$  的点估计, 称为**最大后验估计**.
- 使用后验分布的中位数作为  $\theta$  的点估计, 称为**后验中位数估计**.
- 使用后验分布的均值作为  $\theta$  的点估计, 称为**后验期望估计**. 这是使用最为频繁的贝叶斯估计.

**5. 共轭先验分布** 设  $\theta$  是总体参数,  $\pi(\theta)$  是其先验分布, 若对任意的样本观测值得到的后验分布  $\pi(\theta | X)$  与  $\pi(\theta)$  属于同一个分布族, 则称该分布族是  $\theta$  的**共轭先验分布(族)**.

- 二项分布  $b(n, \theta)$  中的成功概率  $\theta$  的共轭先验分布是贝塔分布  $Be(a, b)$ .
- 泊松分布  $P(\theta)$  中的均值  $\theta$  的共轭先验分布是伽马分布  $Ga(\alpha, \lambda)$ .
- 在方差已知时, 正态均值  $\theta$  的共轭先验分布是正态分布  $N(\mu, \tau^2)$ .
- 在均值已知时, 正态方差  $\sigma^2$  的共轭先验分布是倒伽马分布  $IGa(\alpha, \lambda)$  (若  $X \sim Ga(\alpha, \lambda)$ , 则  $X^{-1}$  的分布称为倒伽马分布  $IGa(\alpha, \lambda)$ ).

## § 6.6 区间估计

**1. 置信区间** 设  $\theta$  是总体的一个参数,其参数空间为  $\Theta, x_1, x_2, \dots, x_n$  是来自该总体的样本,对给定的一个  $\alpha (0 < \alpha < 1)$ ,若有两个统计量  $\hat{\theta}_L = \hat{\theta}_L(x_1, x_2, \dots, x_n)$  和  $\hat{\theta}_U = \hat{\theta}_U(x_1, x_2, \dots, x_n)$ ,使得对任意的  $\theta \in \Theta$ ,有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha,$$

则称随机区间  $[\hat{\theta}_L, \hat{\theta}_U]$  是  $\theta$  的置信水平为  $1 - \alpha$  的置信区间,或简称  $[\hat{\theta}_L, \hat{\theta}_U]$  是  $\theta$  的  $1 - \alpha$  置信区间,  $\hat{\theta}_L$  和  $\hat{\theta}_U$  分别称为  $\theta$  的(双侧)置信下限和置信上限.

这里置信水平  $1 - \alpha$  的含义是指在大量使用该置信区间时,至少有  $100(1 - \alpha)\%$  的区间含有  $\theta$ .

**2. 同等置信区间** 在上述记号下,若对给定的  $\alpha (0 < \alpha < 1)$ ,对任意的  $\theta \in \Theta$ ,有

$$P_{\theta}(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha,$$

则称  $[\hat{\theta}_L, \hat{\theta}_U]$  为  $\theta$  的  $1 - \alpha$  同等置信区间.

同等置信区间是把给定的置信水平  $1 - \alpha$  用足了.常在总体为连续分布场合下可以实现.

**3. 置信限** 在上述记号下,若对给定的  $\alpha (0 < \alpha < 1)$  和任意的  $\theta \in \Theta$ ,有

$$P_{\theta}(\hat{\theta}_L \leq \theta) \geq 1 - \alpha, \quad \forall \theta \in \Theta,$$

则称  $\hat{\theta}_L$  是  $\theta$  的置信水平为  $1 - \alpha$  的(单侧)置信下限.假如等号对一切  $\theta \in \Theta$  成立,则称  $\hat{\theta}_L$  是  $\theta$  的  $1 - \alpha$  同等置信下限.若对给定的  $\alpha (0 < \alpha < 1)$  和任意的  $\theta \in \Theta$ ,有

$$P_{\theta}(\hat{\theta}_U \geq \theta) \geq 1 - \alpha,$$

则称  $\hat{\theta}_U$  是  $\theta$  的置信水平为  $1 - \alpha$  的(单侧)置信上限.若等号对一切  $\theta \in \Theta$  成立,则称  $\hat{\theta}_U$  是  $1 - \alpha$  同等置信上限.

**4. 枢轴量法** 寻找同等置信区间常采用枢轴量法,其步骤如下:

- 设法构造一个样本和  $\theta$  的函数  $G = G(x_1, x_2, \dots, x_n, \theta)$ ,使得  $G$  的分布不依赖于未知参数.此种  $G$  被称为枢轴量.



• 适当地选择两个常数  $c, d$ , 使对给定的  $\alpha (0 < \alpha < 1)$ , 有  $P(c \leq G \leq d) = 1 - \alpha$ .

• 若能将  $c \leq G \leq d$  进行不等式等价变形化为  $\hat{\theta}_L \leq \theta \leq \hat{\theta}_U$ , 则有  $P_\theta(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha$ , 最后的  $[\hat{\theta}_L, \hat{\theta}_U]$  就是  $\theta$  的  $1 - \alpha$  同等置信区间.

关于置信区间的构造有两点说明:

• 满足置信水平要求的  $c$  与  $d$  通常不唯一. 若有可能, 应选平均长度  $E(\hat{\theta}_U - \hat{\theta}_L)$  达到最短的  $c$  与  $d$ , 这在  $G$  的分布为对称分布场合通常容易实现.

• 实际中, 选平均长度  $E(\hat{\theta}_U - \hat{\theta}_L)$  尽可能短的  $c$  与  $d$  往往很难实现, 因此, 常这样选择  $c$  与  $d$ , 使得两个尾部概率各为  $\frac{\alpha}{2}$ , 即  $P(G < c) = P(G > d) =$

$\frac{\alpha}{2}$ , 这样的置信区间称为等尾置信区间. 这是在  $G$  的分布为偏态分布场合常采用的方法.

## 5. 常用的置信区间

(1) 设  $x_1, x_2, \dots, x_n$  是来自  $N(\mu, \sigma^2)$  的样本,  $\bar{x}$  为样本均值,  $s$  为样本标准差,  $u_p$  为标准正态分布的  $p$  分位数,  $t_p(k)$  为自由度是  $k$  的  $t$  分布  $t(k)$  的  $p$  分位数,  $\chi_p^2(k)$  为自由度是  $k$  的  $\chi^2$  分布  $\chi^2(k)$  的  $p$  分位数, 取置信水平  $1 - \alpha$ , 则

•  $\sigma$  已知时  $\mu$  的置信区间为  $[\bar{x} - u_{1-\alpha/2} \sigma / \sqrt{n}, \bar{x} + u_{1-\alpha/2} \sigma / \sqrt{n}]$ .

•  $\sigma$  未知时  $\mu$  的置信区间为  $[\bar{x} - t_{1-\alpha/2} s / \sqrt{n}, \bar{x} + t_{1-\alpha/2} s / \sqrt{n}]$ .

•  $\sigma^2$  ( $\mu$  未知) 的置信区间为  $\left[ \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)s^2}{\chi_{\alpha/2}^2(n-1)} \right]$ .

•  $\sigma$  ( $\mu$  未知) 的置信区间为  $\left[ \frac{s\sqrt{n-1}}{\sqrt{\chi_{1-\alpha/2}^2(n-1)}}, \frac{s\sqrt{n-1}}{\sqrt{\chi_{\alpha/2}^2(n-1)}} \right]$ .

(2) 设  $x_1, x_2, \dots, x_m$  是来自  $N(\mu_1, \sigma_1^2)$  的样本,  $\bar{x}$  为其样本均值,  $s_x$  为其样本标准差,  $y_1, y_2, \dots, y_n$  是来自  $N(\mu_2, \sigma_2^2)$  的样本,  $\bar{y}$  为其样本均值,  $s_y$  为其样本标准差,  $u_p, t_p(k)$  含义同上,  $F_p(k_1, k_2)$  为自由度是  $(k_1, k_2)$  的  $F$  分布  $F(k_1, k_2)$  的  $p$  分位数, 取置信水平  $1 - \alpha$ , 则

- $\sigma_1^2$  与  $\sigma_2^2$  均已知时,  $\mu_1 - \mu_2$  的置信区间为  $\left[ \bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}, \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}} \right]$ .

- $\sigma_1^2 = \sigma_2^2$  未知时,  $\mu_1 - \mu_2$  的置信区间为  $\left[ \bar{x} - \bar{y} - \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2), \bar{x} - \bar{y} + \sqrt{\frac{m+n}{mn}} s_w t_{1-\alpha/2}(m+n-2) \right]$ , 其中  $s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2}$ .

- $\frac{\sigma_1^2}{\sigma_2^2} = \theta$  已知时,  $\mu_1 - \mu_2$  的置信区间为  $\left[ \bar{x} - \bar{y} - \sqrt{\frac{m\theta+n}{mn}} s_t t_{1-\alpha/2}(m+n-2), \bar{x} - \bar{y} + \sqrt{\frac{m\theta+n}{mn}} s_t t_{1-\alpha/2}(m+n-2) \right]$ , 其中  $s_t^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2/\theta}{m+n-2}$ .

- $m$  与  $n$  都很大时,  $\mu_1 - \mu_2$  的近似置信区间为  $\left[ \bar{x} - \bar{y} - u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}}, \bar{x} - \bar{y} + u_{1-\alpha/2} \sqrt{\frac{s_x^2}{m} + \frac{s_y^2}{n}} \right]$ .

- 一般场合下  $\mu_1 - \mu_2$  的近似置信区间为  $\left[ \bar{x} - \bar{y} - s_0 t_{1-\alpha/2}(l), \bar{x} - \bar{y} + s_0 t_{1-\alpha/2}(l) \right]$ , 其中  $s_0^2 = s_x^2/m + s_y^2/n$ ,  $l = \frac{s_0^4}{\frac{s_x^4}{m^2(m-1)} + \frac{s_y^4}{n^2(n-1)}}$ .

- 方差比  $\frac{\sigma_1^2}{\sigma_2^2}$  的置信区间为  $\left[ \frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{1-\alpha/2}(m-1, n-1)}, \frac{s_x^2}{s_y^2} \cdot \frac{1}{F_{\alpha/2}(m-1, n-1)} \right]$ .

(3) 设  $x_1, x_2, \dots, x_n$  是来自  $b(1, p)$  的样本,  $\bar{x}$  为其样本均值, 则  $n$  很大时比例  $p$  的置信水平为  $1-\alpha$  的近似置信区间为  $\left[ \bar{x} - u_{1-\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}, \bar{x} + u_{1-\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \right]$ .

**6. 样本量的确定** 控制比率  $p$  的  $1-\alpha$  置信区间长度不超过  $2d_0$  的最小样本量为  $n \geqslant (u_{1-\alpha/2}/2d_0)^2$ .